

# THÔNG TIN CHUNG CỦA NHÓM

- Link YouTube video của báo cáo (tối đa 5 phút):  
<https://youtu.be/GwK24psvKfU>
- Link slides (dạng .pdf đặt trên Github của nhóm):  
<https://github.com/hdsme/CS2205.FEB2025/blob/master/HoangHao-240101044-CS2205.FEB2025.DeCuong.FinalReport.Template.Slide.pdf>
- Thông tin học viên

- Họ và Tên: Hoàng Hào
- MSSV: 240101044



- Lớp: CS2205.FEB2025
- Tự đánh giá (điểm tổng kết môn): 9/10
- Số buổi vắng: 1
- Số câu hỏi QT cá nhân: 4
- Link Github:  
<https://github.com/hdsme/CS2205.FEB2025>

# ĐỀ CƯƠNG NGHIÊN CỨU

## TÊN ĐỀ TÀI (IN HOA)

PHÂN TÍCH LỖI ĐỘNG CƠ CẢM ỨNG BẰNG MẠNG NƠ-RON TÍCH CHẬP  
ĐA ĐẦU VÀO TRÊN DỮ LIỆU ĐO THỰC NGHIỆM

## TÊN ĐỀ TÀI TIẾNG ANH (IN HOA)

INDUCTION MOTOR FAULT ANALYSIS USING MULTI-INPUT  
CONVOLUTIONAL NEURAL NETWORKS ON EXPERIMENTAL  
MEASUREMENT DATA

## TÓM TẮT *(Tối đa 400 từ)*

Động cơ cảm ứng là thiết bị thiết yếu trong các hệ thống công nghiệp, nơi yêu cầu cao về độ tin cậy và vận hành liên tục. Tuy nhiên, các lỗi như hư hỏng vòng bi, lệch trục, mất cân bằng hoặc sự cố điện vẫn có thể xảy ra, gây ảnh hưởng nghiêm trọng đến hiệu suất và độ an toàn của hệ thống. Các phương pháp giám sát hiện tại chủ yếu dựa trên phân tích một nguồn tín hiệu duy nhất (như rung hoặc dòng điện), do đó chưa tận dụng hiệu quả mối liên hệ giữa các dạng tín hiệu, đặc biệt trong các tình huống lỗi phức tạp và nhiễu cao [1], [2].

Với động lực từ nhu cầu thực tiễn đó, đề tài đặt vấn đề: liệu có thể kết hợp dữ liệu rung và dòng điện thông qua mô hình học sâu để nâng cao độ chính xác trong phát hiện và phân loại lỗi động cơ cảm ứng? Từ đó, đề tài đề xuất sử dụng kiến trúc mạng nơ-ron tích chập (CNN) đa đầu vào, gồm hai nhánh xử lý độc lập tín hiệu rung và dòng điện [3]. Đặc trưng được trích xuất từ hai nhánh sẽ được hợp nhất tại tầng phân loại, giúp mô hình khai thác được thông tin bổ trợ từ cả hai nguồn tín hiệu.

Dữ liệu sử dụng trong nghiên cứu được trích xuất từ một bộ dữ liệu thực nghiệm công nghiệp, bao gồm 20 loại lỗi được mô phỏng ở nhiều mức độ nghiêm trọng khác nhau [4]. Dữ liệu đo được thu thập với tần số 20 kHz, đảm bảo độ chi tiết cao. Mô hình được huấn luyện theo phương pháp học có giám sát và đánh giá qua các chỉ số như độ chính xác, F1-score và ma trận nhầm lẫn.

Kết quả kỳ vọng là mô hình có thể phát hiện và phân loại lỗi với độ chính xác cao, kể cả trong các trường hợp lỗi khó phân biệt. Điều này giúp đóng góp cho việc xây dựng các hệ thống bảo trì dự đoán thông minh, nâng cao hiệu quả vận hành và giảm thiểu rủi ro trong công nghiệp [5].

### **GIỚI THIỆU** *(Tối đa 1 trang A4)*

Động cơ cảm ứng là thiết bị then chốt trong các hệ thống công nghiệp, được ứng dụng rộng rãi trong vận hành máy bơm, băng chuyền, quạt công nghiệp, và nhiều thiết bị quay khác. Tính ổn định và khả năng hoạt động liên tục của các thiết bị này ảnh hưởng trực tiếp đến hiệu suất và độ tin cậy của toàn hệ thống. Tuy nhiên, trong quá trình vận hành, động cơ cảm ứng có thể gặp nhiều sự cố như hỏng vòng bi, lệch trục, mất cân bằng, hay lỗi cuộn dây stator – những lỗi nếu không được phát hiện sớm có thể gây dừng máy và thiệt hại lớn [1].

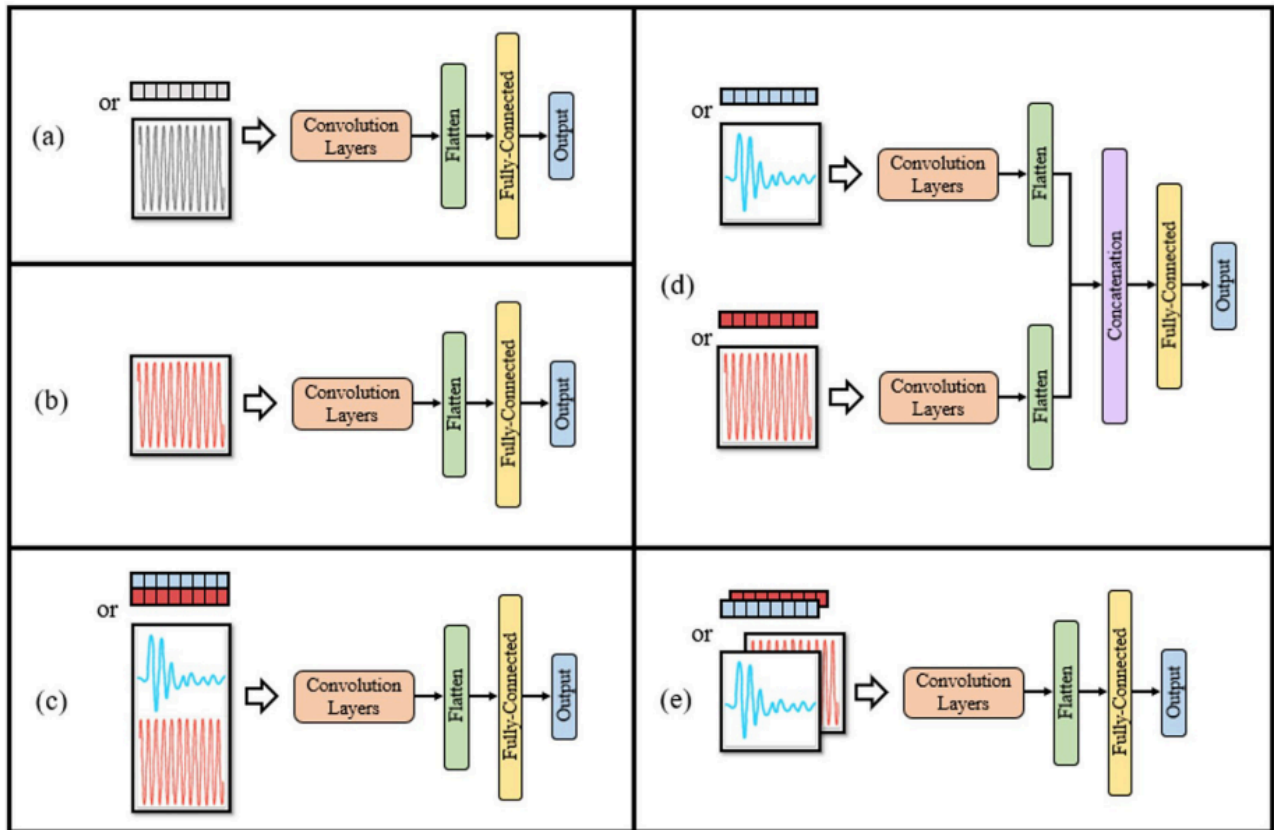
Các phương pháp giám sát hiện nay thường dựa trên một nguồn tín hiệu như rung động hoặc dòng điện. Tuy nhiên, mỗi tín hiệu chỉ phản ánh một khía cạnh của tình trạng máy, và việc phân tích đơn kênh khó có thể nhận diện chính xác các lỗi phức tạp hoặc có biểu hiện tương đồng [2]. Trong khi đó, các phương pháp học sâu như mạng nơ-ron tích chập (CNN) đã chứng minh hiệu quả cao trong phân tích tín hiệu thời gian, nhưng đa phần vẫn chỉ áp dụng cho một loại dữ liệu [3], [4].

Từ vấn đề đó, đề tài này đề xuất xây dựng mô hình CNN đa đầu vào, kết hợp đồng thời tín hiệu rung và dòng điện để phát hiện và phân loại lỗi động cơ cảm ứng. Mô hình sẽ được huấn luyện trên dữ liệu đo thực nghiệm với hơn 20 dạng lỗi khác nhau [5].

Input: tín hiệu rung và dòng điện từ cảm biến.

Output: loại lỗi xảy ra và mức độ nghiêm trọng.

Hướng tiếp cận này kỳ vọng góp phần nâng cao khả năng chẩn đoán sớm và chính xác, hỗ trợ triển khai các hệ thống bảo trì dự đoán trong công nghiệp [6].



Hình 1: Kiến trúc mô hình của phương pháp đề xuất [7]

### MỤC TIÊU (Viết trong vòng 3 mục tiêu)

1. Tiền xử lý và chuẩn hóa bộ dữ liệu đo thực nghiệm từ hệ thống động cơ – bơm, bao gồm tín hiệu rung và dòng điện với nhiều loại lỗi khác nhau, nhằm phục vụ huấn luyện, kiểm định và đánh giá mô hình chẩn đoán [1], [4].
2. Xây dựng kiến trúc mạng nơ-ron tích chập (CNN) đa đầu vào, trong đó mỗi nhánh xử lý một loại tín hiệu (rung hoặc dòng điện), và tích hợp các đặc trưng tại tầng kết hợp để cải thiện khả năng phân loại lỗi động cơ cảm ứng [3], [6].
3. Huấn luyện mô hình trên tập dữ liệu đa dạng lỗi, kiểm thử trên các nhóm lỗi chưa thấy trong huấn luyện, và đánh giá hiệu quả mô hình dựa trên các chỉ số độ chính xác (Accuracy), F1-score và confusion matrix [2], [6].

# NỘI DUNG VÀ PHƯƠNG PHÁP

## 1. Nội dung

- Chuẩn bị, xử lý và tổ chức bộ dữ liệu đo thực nghiệm từ hệ thống động cơ – bơm, bao gồm tín hiệu rung và dòng điện, với nhiều tình huống lỗi khác nhau và mức độ nghiêm trọng đa dạng. Dữ liệu sẽ được chia thành các tập huấn luyện, kiểm định và đánh giá [4], [8].
- Phân tích đặc trưng tín hiệu rung và dòng điện theo cả miền thời gian và miền tần số nhằm tìm hiểu các đặc trưng quan trọng phục vụ cho chẩn đoán lỗi [1], [3].
- Thiết kế mô hình học sâu sử dụng kiến trúc mạng nơ-ron tích chập 1D (1D-CNN) với hai nhánh đầu vào tương ứng với hai loại tín hiệu, thực hiện kết hợp đặc trưng (feature fusion) tại tầng fully connected để phân loại lỗi [3], [6].
- Huấn luyện mô hình trên tập dữ liệu đo thực nghiệm, tinh chỉnh siêu tham số (hyper parameters) trên tập validation và đánh giá hiệu quả phân loại lỗi trên tập test độc lập [2], [6].
- Đánh giá kết quả mô hình thông qua các chỉ số hiệu suất gồm Accuracy, F1-score và confusion matrix, từ đó rút ra nhận xét về khả năng ứng dụng trong bảo trì dự đoán [2], [6].

## 2. Phương pháp

- Tải dữ liệu từ bộ "Motor Current and Vibration Monitoring Dataset for various Faults in an E-motor-driven Centrifugal Pump" từ kho lưu trữ 4TU.ResearchData [4].
- Lựa chọn tín hiệu từ Motor 2 ở ba tốc độ (50%, 75%, 100%) và từ Motor 4 ở tốc độ 70%, bao gồm cả tình huống “Healthy” và hơn 20 dạng lỗi được mô phỏng.
- Chuẩn hóa độ dài tín hiệu: cắt đoạn tín hiệu rung (12 giây, 5 kênh) và dòng điện (15 giây, 3 pha) thành các khung cố định (ví dụ 1 hoặc 2 giây), sau đó chuẩn hóa biên độ về  $[-1, 1]$  [9].

- Định dạng đầu vào: dữ liệu đầu vào được ánh xạ về ma trận đầu vào cho mô hình CNN với kích thước [batch\_size, channels, sequence\_length].
- Xây dựng mô hình CNN đa đầu vào (dual-branch):
- Thiết kế hai nhánh CNN 1D: một nhánh cho tín hiệu rung, một nhánh cho tín hiệu dòng điện.
- Mỗi nhánh gồm chuỗi các lớp Conv1D, BatchNorm, ReLU và MaxPooling để trích xuất đặc trưng cục bộ theo thời gian [3], [7].
- Các đặc trưng học được từ hai nhánh được kết hợp tại tầng fusion (concatenation), sau đó đưa qua các tầng Fully Connected để phân loại lỗi [7], [10].
- Sử dụng hàm mất mát Cross-Entropy cho bài toán phân loại nhiều lớp (multiclass classification) [11].
- Thuật toán tối ưu: Adam với learning rate điều chỉnh qua scheduler [11].
- Huấn luyện trên tập train (80%), tinh chỉnh siêu tham số trên tập validation (10%) và đánh giá trên tập test (10%).
- Đánh giá mô hình dựa trên các chỉ số như Accuracy, F1-score, Confusion Matrix [7], [10].
- So sánh hiệu suất giữa mô hình sử dụng tín hiệu đơn (vibration hoặc current) với mô hình tích hợp hai tín hiệu [7].

## KẾT QUẢ MONG ĐỢI

1. Xây dựng được một mô hình chẩn đoán lỗi động cơ cảm ứng dựa trên kiến trúc mạng nơ-ron tích chập 1D (1D-CNN) đa đầu vào, kết hợp đồng thời tín hiệu rung động và dòng điện thông qua cơ chế hợp nhất đặc trưng tại tầng fully connected.
2. Mô hình được huấn luyện và đánh giá trên bộ dữ liệu thực nghiệm đo từ hệ thống động cơ – bơm, với hơn 20 dạng lỗi khác nhau và ba mức tốc độ hoạt động.
3. Kết quả thực nghiệm kỳ vọng đạt:

- Accuracy > 95% trên tập kiểm thử độc lập,
- F1-score > 0.9 cho đa số các lớp lỗi phổ biến,
- Giảm nhầm lẫn giữa các lỗi tương tự về biểu hiện so với mô hình đơn kênh

## **TÀI LIỆU THAM KHẢO** (*Định dạng DBLP*)

- [1]. W. Zhang, G. Peng, C. Li, Y. Chen, Z. Zhang: A new deep learning model for fault diagnosis with good anti-noise and domain adaptation ability on raw vibration signals, 2017.
- [2]. Y. LeCun, Y. Bengio, G. Hinton: Deep learning, 2015.
- [3]. C. Zhou, Z. He, Y. Zi: A multi-channel convolutional neural network model for fault diagnosis of rotating machinery, 2018.
- [4]. S. Bruinsma, R.D. Geertsma, R. Loendersloot, T. Tinga: Motor current and vibration monitoring dataset for various faults in an E-motor-driven centrifugal pump, 2022.
- [5]. J. Lee, B. Bagheri, C. Jin: Introduction to cyber manufacturing, 2016.
- [6]. H. Shao, H. Jiang, H. Zhang, Y. Niu: Rolling bearing fault diagnosis using an optimized deep convolutional neural network, 2018.
- [7]. M. Abdelmaksoud, M. Torki, M. El-Habrouk, M. Elgeneidy: Convolutional neural network based multi-signals fault diagnosis of induction motor using single and multi-channels datasets, 2022.
- [8]. R. Wang, J. Tang, J. Sun, Y. Lei: Data-driven fault diagnosis and fault-tolerant control of industrial processes: A review, IEEE Transactions on Industrial Informatics, 2020.
- [9]. H. Wang, K. Peng, Y. Li: Fault diagnosis of induction motor based on wavelet packet transform and deep neural networks, 2019.
- [10]. L. Zhang, Z. Yang, M. Chen: A deep learning-based method for fault diagnosis of rotating machinery using multi-sensor data fusion, 2019.
- [11]. D.P. Kingma, J. Ba: Adam: A Method for Stochastic Optimization, 2014.

